

Borrador de Trabajo Científico:

Minería de Datos aplicada a la Evolución Arquitectónica de GPUs: De la Ley de Moore al Paradigma de Amdahl (1986-2026)

El problema

El ecosistema del hardware gráfico (GPUs) ha evolucionado drásticamente en las últimas cuatro décadas. Históricamente, el aumento de rendimiento se lograba incrementando la densidad de transistores y la frecuencia de reloj. Sin embargo, al alcanzar los límites térmicos físicos (el "muro de energía"), la industria tuvo que cambiar su paradigma hacia el paralelismo masivo.

El problema a resolver es **demostrar empíricamente este cambio de paradigma**. Se busca modelar matemáticamente cómo se ha comportado la densidad de transistores a lo largo del tiempo y detectar, mediante técnicas de minería de datos, en qué momento exacto la arquitectura dejó de priorizar los gigahercios para centrarse en multiplicar los núcleos, validando así la transición del dominio de la Ley de Moore al de la Ley de Amdahl.

La aplicación

Se abordarán dos enfoques principales:

- **Regresión (Supervisada):** Para modelar el crecimiento no lineal (exponencial y logarítmico) del número de transistores, núcleos y frecuencias a lo largo de los años.
- **Clustering (No supervisado):** Para segmentar la base de datos no por gamas de precio, sino por "eras arquitectónicas" (ej. *Era de la Frecuencia* vs. *Era del Paralelismo*), agrupando las tarjetas gráficas según sus características físicas subyacentes sin usar la fecha como variable de entrada.

El dataset

Se utilizará el dataset abierto de Kaggle "**GPUs Specs From 1986 to 2026**", el cual recopila casi 40 años de especificaciones técnicas de tarjetas gráficas (NVIDIA, AMD/ATI, Intel).

- *Descripción:* Contiene variables críticas como el proceso de fabricación (nm), recuento de transistores, tamaño del *die*, frecuencia de reloj, número de núcleos/Shader y TDP (consumo energético).
- *Tratamiento:* La complejidad radicará en la limpieza de datos históricos (imputación de valores nulos en hardware de los años 90), la conversión de unidades a una escala

común y la aplicación de transformaciones logarítmicas a las variables con crecimiento exponencial para facilitar el modelado.

El algoritmo o algoritmos

Para validar la Ley de Moore y modelar el estancamiento de la frecuencia, se usarán algoritmos de **Regresión Polinómica** y **Random Forest Regressor**, justificando su uso por su capacidad para capturar relaciones no lineales complejas y proporcionar la importancia de cada característica (*Feature Importance*).

- Para el descubrimiento de las "eras arquitectónicas", se empleará el algoritmo de clustering **K-Means**, parametrizando el valor óptimo de clústeres (k) mediante el método del codo y el análisis de la silueta.

Proceso:

- 1. **Selección:** Descarga del dataset desde Kaggle e importación en un entorno Python.
- 2. **Análisis:** Análisis Exploratorio de Datos (EDA) para visualizar la evolución temporal de los transistores frente a los núcleos y frecuencias.
- 3. **Transformación:** Limpieza de nulos, estandarización (Z-score) de variables continuas y transformaciones logarítmicas.
- 4. **Técnica:** Aplicación de *Clustering* para segmentación temporal ciega y de Regresión para el modelado de crecimiento.
- 5. **Extracción:** Extracción de los puntos de inflexión históricos y las reglas que definen cada era del hardware.
- 6. **Interpretación:** Traducción de los modelos matemáticos a conceptos de Arquitectura de Computadores.

Diseño experimental

Para los modelos de regresión, el dataset se dividirá cronológicamente (*Time Series Split*) en lugar de un *Holdout* aleatorio tradicional, ya que se busca predecir el comportamiento futuro basándose en el pasado. Se utilizarán métricas como la Raíz del Error Cuadrático Medio (RMSE) y el coeficiente de determinación (R2). Para el clustering, se evaluará la cohesión y separación interna de los grupos formados.

Resultados y análisis

El análisis buscará correlacionar los hallazgos de los algoritmos con dos fundamentos teóricos que se desarrollarán en el artículo.

Primero, se contrastará el crecimiento de transistores con la formulación de la Ley de Moore:

$$N(t) = N_0 \cdot 2^{t/2}$$

Segundo, se analizará cómo la explosión en el recuento de núcleos descubierta por los algoritmos intenta maximizar la aceleración teórica (S) dictada por la Ley de Amdahl para cargas de trabajo paralelizables (p):

$$S(n) = \frac{1}{(1 - p) + \frac{p}{n}}$$

Se espera demostrar que la minería de datos es capaz de redescubrir, a partir de datos crudos, los mismos muros físicos que obligaron a la industria tecnológica a cambiar su diseño de hardware.

Referencias bibliográficas

- Dataset: Kaggle - *GPUs Specs From 1986 to 2026*.
- Moore, G. E. (1965). *Cramming more components onto integrated circuits*.
- Amdahl, G. M. (1967). *Validity of the single processor approach to achieving large scale computing capabilities*.